utfcode
utf8.sty 3.10 UTF-8 input encoding 13.06.2000
scanner for code UTF-8 installed.



UNIVERSIDAD NACIONAL DE COLOMBIA

Facultad de Ciencias

Aprendizaje Automático

Taller 1

David López López
Breadley Josshuen Marin Velasco

Medellín, Colombia

Octubre de 2026

Notación y convención de las pérdidas

Sea el conjunto de datos $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, con $X \in \mathbb{R}^{N\times D}$, matriz de parámetros $w \in \mathbb{R}^D$ e intercepto $b \in \mathbb{R}$. Las filas de X corresponden a las observaciones. En regresión, $y_n \in \mathbb{R}$; en clasificación binaria, $y_n \in \{0, 1\}$.

Definimos la puntuación lineal z como:

$$z = Xw + b\mathbf{1}_N \tag{1}$$

Las funciones de pérdida de referencia corresponden a:

- **Pérdida por error cuadrático medio (Regresión):**

$$J_{\text{reg}}(w, b) = \frac{1}{2N}\|z - y\|_2^2 \tag{2}$$

- **Pérdida de entropía cruzada binaria (Regresión Logística):**

$$J_{\log}(w, b) = -\frac{1}{N}\sum_{n=1}^{N}[y_n \log p_n + (1 - y_n)\log(1 - p_n)] \tag{3}$$

  donde la probabilidad estimada es $p_n = \sigma(z_n) = \frac{1}{1+e^{-z_n}}$.

- **Objetivo regularizado general:**

$$F(w, b) = J(w, b) + \lambda_1\|w\|_1 + \frac{\lambda_2}{2}\|w\|_2^2, \quad \text{con } \lambda_1, \lambda_2 \geq 0 \tag{4}$$

1. Parte I. Fundamentación teórica

Problema 1. Mínimos cuadrados, Ridge y estabilidad

a) Log-verosimilitud, gradiente, Hessiano y ecuaciones normales de Ridge

1. Derivación de la log-verosimilitud y relación con $J_{\text{reg}}(w, b)$: Dado que las observaciones $Y_n \mid x_n \sim \mathcal{N}(w^\top x_n + b, \sigma^2)$ son condicionalmente independientes con varianza $\sigma^2 > 0$ conocida, la función de densidad de probabilidad para cada observación es:

$$p(y_n \mid x_n; w, b, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(y_n - (w^\top x_n + b))^2}{2\sigma^2}\right) \tag{5}$$

La función de verosimilitud $L(w, b)$ para las N observaciones independientes corresponde al producto de las densidades:

$$L(w, b) = \prod_{n=1}^{N} p(y_n \mid x_n; w, b, \sigma^2) = \left(2\pi\sigma^2\right)^{-\frac{N}{2}}\exp\left(-\frac{1}{2\sigma^2}\sum_{n=1}^{N}(y_n - (w^\top x_n + b))^2\right) \tag{6}$$

Aplicando logaritmo natural, obtenemos la función de log-verosimilitud $\ell(w, b)$:

$$\ell(w, b) = \ln L(w, b) = -\frac{N}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{n=1}^{N}\Big(y_n - (w^\top x_n + b)\Big)^2 \tag{7}$$

Utilizando la notación vectorial definida con $z = Xw + b\mathbf{1}_N$, donde $z_n = w^\top x_n + b$, la suma de errores al cuadrado se reescribe como $\|z - y\|_2^2$:

$$\ell(w, b) = -\frac{N}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|z - y\|_2^2 \tag{8}$$

Para encontrar los estimadores de Máxima Verosimilitud (MLE), maximizamos $\ell(w, b)$, lo cual equivale a minimizar la log-verosimilitud negativa $-\ell(w, b)$:

$$\arg\min_{w,b} [-\ell(w, b)] = \arg\min_{w,b} \left[\frac{N}{2} \ln(2\pi\sigma^2) + \frac{1}{2\sigma^2} \|z - y\|_2^2 \right] \tag{9}$$

Puesto que el primer término es una constante con respecto a w y b, y multiplicando la función objetivo por el escalar positivo constante $\frac{\sigma^2}{N}$, preservamos el minimizador exacto:

$$\arg\min_{w,b} [-\ell(w, b)] = \arg\min_{w,b} \frac{1}{2N} \|z - y\|_2^2 = \arg\min_{w,b} J_{\text{reg}}(w, b) \tag{10}$$

Conclusión de la relación: La estimación por máxima verosimilitud bajo el supuesto de errores Gaussianos independientes e idénticamente distribuidos (i.i.d.) es equivalente a la minimización de la pérdida del error cuadrático medio $J_{\text{reg}}(w, b)$.

2. Derivación del gradiente, Hessiano y ecuaciones normales de Ridge: Definimos la matriz de diseño aumentada $\tilde{X} = [\mathbf{1}_N \quad X]$, el vector de parámetros aumentado $\theta = \begin{bmatrix} b \\ w \end{bmatrix}$ y la matriz diagonal de selección de penalización $P = \text{diag}(0, 1, \ldots, 1)$. Notemos que $\tilde{X}\theta = b\mathbf{1}_N + Xw = z$ y que:

$$\theta^\top P \theta = \begin{bmatrix} b & w^\top \end{bmatrix} \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & I_D \end{bmatrix} \begin{bmatrix} b \\ w \end{bmatrix} = w^\top w = \|w\|_2^2 \tag{11}$$

Bajo la convención de pérdida (4) con $\lambda_1 = 0$ (regularización Ridge), la función objetivo $F(\theta)$ se expresa como:

$$F(\theta) = \frac{1}{2N} \|\tilde{X}\theta - y\|_2^2 + \frac{\lambda_2}{2} \theta^\top P \theta = \frac{1}{2N} \left(\theta^\top \tilde{X}^\top \tilde{X} \theta - 2y^\top \tilde{X} \theta + y^\top y \right) + \frac{\lambda_2}{2} \theta^\top P \theta \tag{12}$$

- **Gradiente ($\nabla_\theta F(\theta)$):** Derivando respecto a θ:

$$\nabla_\theta F(\theta) = \frac{1}{N} \tilde{X}^\top (\tilde{X}\theta - y) + \lambda_2 P \theta \tag{13}$$

- **Hessiano ($\nabla_\theta^2 F(\theta)$):** Derivando el gradiente con respecto a θ:

$$\nabla_\theta^2 F(\theta) = \frac{1}{N} \tilde{X}^\top \tilde{X} + \lambda_2 P \tag{14}$$

- **Ecuaciones Normales de Ridge:** Igualando el gradiente a cero ($\nabla_\theta F(\hat{\theta}) = \mathbf{0}$):

$$\frac{1}{N} \tilde{X}^\top (\tilde{X}\hat{\theta} - y) + \lambda_2 P \hat{\theta} = \mathbf{0} \implies \left(\frac{1}{N} \tilde{X}^\top \tilde{X} + \lambda_2 P \right) \hat{\theta} = \frac{1}{N} \tilde{X}^\top y \tag{15}$$

  Multiplicando por N, se obtienen las ecuaciones normales:

$$\left(\tilde{X}^\top \tilde{X} + N\lambda_2 P \right) \hat{\theta} = \tilde{X}^\top y \tag{16}$$

3. Dimensiones de cada término:

Término	Descripción	Dimensión
N	Número de observaciones	$\mathbb{N}^+$
D	Número de características (predictores)	$\mathbb{N}^+$
X	Matriz de características original	$N \times D$
$\mathbf{1}_N$	Vector columna de unos	$N \times 1$
$\tilde{X}$	Matriz de características aumentada $[\mathbf{1}_N \quad X]$	$N \times (D+1)$
y	Vector de respuestas observadas	$N \times 1$
w	Vector de coeficientes de regresión	$D \times 1$
b	Intercepto / término de sesgo	$\mathbb{R}$
θ	Vector de parámetros aumentado $[b, w^\top]^\top$	$(D+1) \times 1$
P	Matriz de penalización $\text{diag}(0, 1, \ldots, 1)$	$(D+1) \times (D+1)$
λ_2	Hiperparámetro de regularización L_2	$\mathbb{R}_{\geq 0}$
z	Puntuación lineal $\tilde{X}\theta$	$N \times 1$
$\nabla_\theta F(\theta)$	Vector gradiente de la función de pérdida	$(D+1) \times 1$
$\nabla^2_\theta F(\theta)$	Matriz Hessiana de la función de pérdida	$(D+1) \times (D+1)$
$\tilde{X}^\top \tilde{X}$	Matriz Gram aumentada	$(D+1) \times (D+1)$
$\tilde{X}^\top y$	Vector de covarianza cruzada empírica	$(D+1) \times 1$

Cuadro 1: Dimensiones de las variables y operadores involucrados en Ridge.

b) Unicidad de la solución de OLS y Ridge, y proyección ortogonal

1. Condición para la unicidad de la solución en Mínimos Cuadrados Ordinarios (OLS): Las ecuaciones normales de OLS para el modelo aumentado corresponden a $\tilde{X}^\top \tilde{X}\theta = \tilde{X}^\top y$. La solución $\hat{\theta}_{\text{OLS}} = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top y$ existe y es única si y solo si la matriz Gram aumentada $\tilde{X}^\top \tilde{X} \in \mathbb{R}^{(D+1)\times(D+1)}$ es invertible (estrictamente definida positiva).

Esto se cumple si y solo si la matriz de diseño aumentada $\tilde{X} = [\mathbf{1}_N \quad X]$ tiene **rango columna completo**:

$$\text{rango}(\tilde{X}) = D + 1 \tag{17}$$

Las condiciones necesarias y suficientes son:

1. $N \geq D + 1$ (el número de observaciones debe ser mayor o igual al número de parámetros a estimar).

2. Ninguna columna de X es combinación lineal de las demás ni del vector constante de unos $\mathbf{1}_N$.

Si las columnas de X son linealmente dependientes, la matriz $\tilde{X}^\top \tilde{X}$ es singular, lo que genera infinitas soluciones posibles.

2. Demostración de unicidad de la solución Ridge con columnas dependientes ($\lambda_2 > 0$, $N \geq 1$): El sistema de ecuaciones normales de Ridge es $A\hat{\theta} = \tilde{X}^\top y$, con la matriz del sistema definida por:

$$A = \tilde{X}^\top \tilde{X} + N\lambda_2 P \tag{18}$$

donde $P = \text{diag}(0, 1, \ldots, 1) = \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & I_D \end{bmatrix}$.

Para probar que la solución es única independientemente de la dependencia lineal de las columnas de X, demostraremos que la matriz A es estrictamente definida positiva ($u^\top A u > 0$, $\forall u \neq \mathbf{0}$).

Sea un vector no nulo arbitrario $u = \begin{bmatrix}\alpha \\ v\end{bmatrix} \in \mathbb{R}^{D+1}$, con $\alpha \in \mathbb{R}$ para el intercepto y $v \in \mathbb{R}^D$ para los coeficientes. Evaluando la forma cuadrática:

$$u^\top A u = u^\top \left(\tilde{X}^\top \tilde{X} + N\lambda_2 P\right) u = \|\tilde{X}u\|_2^2 + N\lambda_2 u^\top P u \tag{19}$$

Dado que $u^\top P u = v^\top I_D v = \|v\|_2^2$, la expresión se simplifica a:

$$u^\top A u = \|\tilde{X}u\|_2^2 + N\lambda_2 \|v\|_2^2 \geq 0 \tag{20}$$

Evaluando la condición de nula igualdad $u^\top A u = 0$:

- Dado $N \geq 1$ y $\lambda_2 > 0$, el término $N\lambda_2\|v\|_2^2 = 0$ exige estrictamente que $\|v\|_2^2 = 0 \implies v = \mathbf{0}$.
- Sustituyendo $v = \mathbf{0}$ en la norma restante, obtenemos:

$$\left\| \tilde{X} \begin{bmatrix}\alpha \\ \mathbf{0}\end{bmatrix} \right\|_2^2 = \|\alpha \mathbf{1}_N\|_2^2 = \alpha^2 N = 0 \tag{21}$$

  Como $N \geq 1$, se requiere que $\alpha = 0$.

Por lo tanto, $u^\top A u = 0 \iff u = \mathbf{0}$, demostrando que A es estrictamente definida positiva y garantizando que la solución Ridge $\hat{\theta}_{\text{Ridge}} = A^{-1}\tilde{X}^\top y$ es **única** aun con columnas dependientes.

3. Comparación de $X^\top r$ en OLS y Ridge: Definiendo el vector de residuos como $r = y - \tilde{X}\hat{\theta}$:

- **En OLS:** De la condición de primer orden $\tilde{X}^\top r_{\text{OLS}} = \mathbf{0}$, se deduce que:

$$\mathbf{1}_N^\top r_{\text{OLS}} = 0 \quad \text{y} \quad X^\top r_{\text{OLS}} = \mathbf{0} \tag{22}$$

- **En Ridge:** De la condición de optimalidad $\tilde{X}^\top(\tilde{X}\hat{\theta} - y) + N\lambda_2 P\hat{\theta} = \mathbf{0}$:

$$-\tilde{X}^\top r_{\text{Ridge}} + N\lambda_2 P\hat{\theta} = \mathbf{0} \implies \tilde{X}^\top r_{\text{Ridge}} = N\lambda_2 P\hat{\theta} \tag{23}$$

  Descomponiendo por bloques para las características X:

$$X^\top r_{\text{Ridge}} = N\lambda_2 \hat{w}_{\text{Ridge}} \tag{24}$$

4. Análisis sobre la condición de proyección ortogonal. No es correcto denominar proyección ortogonal al ajuste Ridge. Por simplicidad, consideremos $b = 0$; con intercepto no penalizado el argumento es análogo. Los valores ajustados son $\hat{y}_{\text{Ridge}} = H_{\lambda_2}\, y$, donde

$$H_{\lambda_2} = X\,(X^\top X + N\lambda_2 I_D)^{-1} X^\top. \tag{25}$$

Una proyección sobre un subespacio debe ser simétrica e idempotente ($H^2 = H$). La matriz H_{λ_2} es simétrica. Sea $X = U\Sigma V^\top$ la descomposición en valores singulares, con $d_j = \sigma_j^2 > 0$. Los autovalores de H_{λ_2} son

$$\frac{d_j}{d_j + N\lambda_2} \in (0,1), \qquad \lambda_2 > 0, \tag{26}$$

y como $\frac{d_j^2}{(d_j+N\lambda_2)^2} \neq \frac{d_j}{d_j+N\lambda_2}$ para $\lambda_2 > 0$, se cumple

$$H_{\lambda_2}^2 \neq H_{\lambda_2}. \tag{27}$$

Por tanto, Ridge no es una proyección de ningún tipo. Es un operador lineal simétrico de contracción que reduce el ajuste en cada dirección singular por el factor $d_j/(d_j + N\lambda_2)$. Esto también se refleja en la condición de optimalidad: $X^\top r_{\text{Ridge}} = N\lambda_2\, \hat{w}_{\text{Ridge}} \neq 0$, de modo que los residuos no son ortogonales al espacio columna.

c) Esperanza, covarianza, representación espectral y error cuadrático en Ridge

1. Derivación de la esperanza y covarianza condicionales: Considerando $b = 0$, el estimador de Ridge se define como $\hat{w}_{\lambda_2} = (X^\top X + N\lambda_2 I_D)^{-1} X^\top y$. Sustituyendo el modelo de generación de datos $y = Xw^* + \epsilon$, donde $\epsilon \sim \mathcal{N}(0, \sigma^2 I_N)$:

$$\hat{w}_{\lambda_2} = (X^\top X + N\lambda_2 I_D)^{-1} X^\top (Xw^* + \epsilon) = (X^\top X + N\lambda_2 I_D)^{-1} X^\top X w^* + (X^\top X + N\lambda_2 I_D)^{-1} X^\top \epsilon \tag{28}$$

- **Esperanza condicional ($\mathbb{E}[\hat{w}_{\lambda_2} \mid X]$):** Dado que $\mathbb{E}[\epsilon \mid X] = \mathbf{0}$:

$$\mathbb{E}[\hat{w}_{\lambda_2} \mid X] = (X^\top X + N\lambda_2 I_D)^{-1} X^\top X w^* \tag{29}$$

  El vector de sesgo estadístico resultante corresponde a:

$$\text{Sesgo}(\hat{w}_{\lambda_2} \mid X) = \mathbb{E}[\hat{w}_{\lambda_2} \mid X] - w^* = -N\lambda_2 (X^\top X + N\lambda_2 I_D)^{-1} w^* \tag{30}$$

- **Covarianza condicional ($\mathbf{Cov}(\hat{w}_{\lambda_2} \mid X)$):** Aplicando las propiedades de la covarianza con $\text{Cov}(\epsilon \mid X) = \sigma^2 I_N$:

$$\text{Cov}(\hat{w}_{\lambda_2} \mid X) = \sigma^2 (X^\top X + N\lambda_2 I_D)^{-1} X^\top X (X^\top X + N\lambda_2 I_D)^{-1} \tag{31}$$

2. Expresión en las direcciones propias de $X^\top X$: Sea $X^\top X = V \Lambda V^\top$ la descomposición espectral de la matriz Gram, con $V = [v_1, \ldots, v_D]$ una matriz ortogonal ($V^\top V = I_D$) y $\Lambda = \text{diag}(d_1, \ldots, d_D)$ la matriz de autovalores $d_j > 0$. Expresando w^* en la base de autovectores como $w^* = V\alpha$ con $\alpha_j = v_j^\top w^*$:

- **Componentes del sesgo:** Para cada dirección propia $j \in \{1, \ldots, D\}$:

$$\text{Sesgo}_j = -\frac{N\lambda_2}{d_j + N\lambda_2} \alpha_j \implies \|\text{Sesgo}(\hat{w}_{\lambda_2} \mid X)\|_2^2 = \sum_{j=1}^{D} \frac{(N\lambda_2)^2}{(d_j + N\lambda_2)^2} \alpha_j^2 \tag{32}$$

- **Varianza total (Traza de la Covarianza):**

$$\text{Var}(\hat{w}_{\lambda_2} \mid X) = \text{tr}(\text{Cov}(\hat{w}_{\lambda_2} \mid X)) = \sigma^2 \sum_{j=1}^{D} \frac{d_j}{(d_j + N\lambda_2)^2} \tag{33}$$

3. Análisis de los límites $\lambda_2 \to 0$ y $\lambda_2 \to \infty$:

- **Límite $\lambda_2 \to 0$ (OLS):** Sesgo $\to \mathbf{0}$ (estimador insesgado), mientras que la varianza total se reduce a $\sigma^2 \sum_{j=1}^{D} \frac{1}{d_j}$. Si existen autovalores $d_j \approx 0$ (multicolinealidad), la varianza tiende a infinito.
- **Límite $\lambda_2 \to \infty$ (Penalización extrema):** $\mathbb{E}[\hat{w}_{\lambda_2} \mid X] \to \mathbf{0}$, generando un sesgo que tiende a $-w^*$ y una varianza que se anula por completo (Var $\to 0$).

4. Relación entre varianza y Error Cuadrático Medio (MSE): El MSE total de estimación se descompone exactamente en la suma de la norma del sesgo al cuadrado y la varianza total:

$$\text{MSE}(\hat{w}_{\lambda_2}) = \sum_{j=1}^{D} \frac{(N\lambda_2)^2 \alpha_j^2 + \sigma^2 d_j}{(d_j + N\lambda_2)^2} \tag{34}$$

Aunque la varianza es una función estrictamente decreciente de λ_2, el sesgo al cuadrado es estrictamente creciente a partir de cero. Para valores pequeños de $\lambda_2 > 0$, la reducción de varianza domina el incremento del sesgo, reduciendo el MSE global. Sin embargo, para valores elevados de regularización, el sesgo al cuadrado crece mucho más rápido de lo que disminuye la varianza residual, ocasionando que el MSE total se incremente. Por lo tanto, disminuir la varianza no garantiza un menor error cuadrático medio para cualquier intensidad de regularización.

Problema 2. Lasso, esparsidad y representación

a) Descomposición del objetivo Lasso y regla de umbral suave (Soft-Thresholding)

1. Descomposición del objetivo en problemas escalares independientes: Considerando un modelo sin intercepto ($b = 0$), datos centrados, matriz de diseño ortonormal ponderada $X^\top X/N = I_D$ y definiendo el vector de correlación empírica $s = X^\top y/N$, la función objetivo de Lasso corresponde a:

$$F(w) = \frac{1}{2N}\|Xw - y\|_2^2 + \lambda_1\|w\|_1 \tag{35}$$

Desarrollando el término cuadrático de residuos:

$$\frac{1}{2N}\|Xw - y\|_2^2 = \frac{1}{2N}\left(w^\top X^\top Xw - 2y^\top Xw + y^\top y\right) \tag{36}$$

Sustituyendo $X^\top X = NI_D$ y $\frac{1}{N}X^\top y = s$:

$$\frac{1}{2N}w^\top(NI_D)w = \frac{1}{2}w^\top w = \frac{1}{2}\sum_{j=1}^{D} w_j^2 \tag{37}$$

$$\frac{1}{N}y^\top Xw = \left(\frac{X^\top y}{N}\right)^\top w = s^\top w = \sum_{j=1}^{D} s_j w_j \tag{38}$$

Reemplazando en la función objetivo $F(w)$:

$$F(w) = \sum_{j=1}^{D}\left(\frac{1}{2}w_j^2 - s_j w_j + \lambda_1|w_j|\right) + \frac{\|y\|_2^2}{2N} \tag{39}$$

Dado que $\frac{\|y\|_2^2}{2N}$ es constante respecto a w, la optimización multivariada se desacopla exactamente en D problemas de optimización escalar independientes:

$$\min_w F(w) \iff \sum_{j=1}^{D}\left[\min_{w_j} g_j(w_j)\right] + \text{constante}, \quad \text{con } g_j(w_j) = \frac{1}{2}w_j^2 - s_j w_j + \lambda_1|w_j| \tag{40}$$

2. Resolución analítica por casos para $g_j(w_j)$: Analizamos la función estrictamente convexa $g_j(w_j)$ para cada coordenada $j \in \{1, \ldots, D\}$:

- **Caso 1 ($w_j > 0$):** La función es diferenciable con $|w_j| = w_j$:

$$g_j'(w_j) = w_j - s_j + \lambda_1 = 0 \implies w_j = s_j - \lambda_1 \tag{41}$$

  Esta solución es admisible en la región $w_j > 0$ si y solo si $s_j > \lambda_1$.

- **Caso 2 ($w_j < 0$):** La función es diferenciable con $|w_j| = -w_j$:

$$g_j'(w_j) = w_j - s_j - \lambda_1 = 0 \implies w_j = s_j + \lambda_1 \tag{42}$$

  Esta solución es admisible en la región $w_j < 0$ si y solo si $s_j < -\lambda_1$.

- **Caso 3 ($w_j = 0$ y justificación del intervalo por subdiferencial):** Puesto que $|w_j|$ no es diferenciable en cero, empleamos su subdiferencial $\partial|0| = [-1, 1]$. La condición de optimalidad de primer orden para optimización convexa no diferenciable exige que:

$$0 \in \partial g_j(0) \tag{43}$$

Calculando el subdiferencial de g_j en el origen:

$$\partial g_j(0) = 0 - s_j + \lambda_1 \partial|0| = -s_j + \lambda_1[-1, 1] = [-s_j - \lambda_1,\ -s_j + \lambda_1] \tag{44}$$

Para que $0 \in [-s_j - \lambda_1,\ -s_j + \lambda_1]$, se debe cumplir simultáneamente:

$$-s_j - \lambda_1 \leq 0 \quad \text{y} \quad -s_j + \lambda_1 \geq 0 \iff -\lambda_1 \leq s_j \leq \lambda_1 \iff |s_j| \leq \lambda_1 \tag{45}$$

Por consiguiente, $\hat{w}_j = 0$ si y solo si $s_j \in [-\lambda_1, \lambda_1]$.

3. Regla de umbral suave (Soft-Thresholding): Combinando los tres casos, la solución óptima para cada coeficiente se expresa mediante el operador de umbral suave $\mathcal{S}_{\lambda_1}(s_j)$:

$$\hat{w}_j = \mathcal{S}_{\lambda_1}(s_j) = \begin{cases} s_j - \lambda_1 & \text{si } s_j > \lambda_1 \\ 0 & \text{si } |s_j| \leq \lambda_1 \\ s_j + \lambda_1 & \text{si } s_j < -\lambda_1 \end{cases} \tag{46}$$

O equivalentemente en formato compacto:

$$\hat{w}_j = \text{sign}(s_j)\, \text{máx}(0, |s_j| - \lambda_1) \tag{47}$$

b) Optimalidad coordenada a coordenada y análisis de columnas idénticas

1. Condiciones de optimalidad coordenada a coordenada en términos de residuos: Considerando la función de pérdida Lasso $F(w) = \frac{1}{2N}\|y - Xw\|_2^2 + \lambda_1\|w\|_1$, aislamos el coeficiente w_j manteniendo fijos los demás parámetros w_k $(k \neq j)$. Definiendo el residuo parcial $r^{(j)} \in \mathbb{R}^N$ no explicado por las demás variables como:

$$r^{(j)} = y - \sum_{k \neq j} x_k w_k = (y - Xw) + x_j w_j \tag{48}$$

La función de pérdida aislada para la coordenada w_j se reescribe como:

$$g_j(w_j) = \frac{1}{2N}\|r^{(j)} - x_j w_j\|_2^2 + \lambda_1|w_j| = \frac{1}{2N}\left(\|r^{(j)}\|_2^2 - 2w_j x_j^\top r^{(j)} + w_j^2\|x_j\|_2^2\right) + \lambda_1|w_j| \tag{49}$$

Aplicando la condición de subgradiente respecto a w_j:

$$\partial_{w_j} g_j(w_j) = \frac{\|x_j\|_2^2}{N} w_j - \frac{x_j^\top r^{(j)}}{N} + \lambda_1 \partial|w_j| \ni 0 \tag{50}$$

Definiendo la correlación parcial $\rho_j = \frac{1}{N} x_j^\top r^{(j)}$ y el factor de escala $z_j = \frac{1}{N}\|x_j\|_2^2$, la regla de actualización exacta resulta:

$$\hat{w}_j = \frac{1}{\|x_j\|_2^2/N}\, \mathcal{S}_{\lambda_1}\left(\frac{1}{N} x_j^\top r^{(j)}\right) \tag{51}$$

donde $\mathcal{S}_{\lambda_1}(\rho) = \text{sign}(\rho)\, \text{máx}(0, |\rho| - \lambda_1)$ representa el operador de umbral suave.

2. Comparación de minimizadores con columnas idénticas ($x_1 = x_2$): Bajo el supuesto de dos columnas idénticas cuya contribución conjunta exige la restricción $w_1 + w_2 = s \neq 0$ (asumiendo sin pérdida de generalidad $s > 0$), comparamos la minimización de la penalización L_2 y L_1:

- **Minimización de L_2 $(w_1^2 + w_2^2)$:** Sustituyendo $w_2 = s - w_1$:

$$h(w_1) = w_1^2 + (s - w_1)^2 = 2w_1^2 - 2sw_1 + s^2 \implies h'(w_1) = 4w_1 - 2s = 0 \implies w_1^* = \frac{s}{2}, \quad w_2^* = \frac{s}{2} \tag{52}$$

  Existe un **único minimizador** $(w_1^*, w_2^*) = \left(\frac{s}{2}, \frac{s}{2}\right)$, repartiendo la penalización en partes iguales.

- **Minimización de L_1 $(|w_1| + |w_2|)$:** Sustituyendo $w_2 = s - w_1$ para $s > 0$: Para $0 \leq w_1 \leq s$, ambos términos son no negativos, luego $|w_1| + |w_2| = w_1 + (s - w_1) = s$. Para $w_1 < 0$ o $w_1 > s$, la suma satisface $|w_1| + |w_2| > s$. Por lo tanto, la norma L_1 alcanza el valor mínimo constante s sobre todo el segmento continuo $\{(w_1, w_2) : w_1 + w_2 = s,\ w_1 \geq 0,\ w_2 \geq 0\}$, generando un **conjunto infinito de minimizadores**.

3. Conclusiones sobre unicidad, estabilidad y selección de variables:

- **Unicidad y estabilidad.** La norma ℓ_1 es convexa, pero no estrictamente convexa. En este caso, la presencia de columnas idénticas hace que la parte cuadrática dependa de (w_1, w_2) únicamente a través de $w_1 + w_2$. Sobre el segmento $\{(w_1, w_2) : w_1 + w_2 = s,\ w_1, w_2 \geq 0\}$ la penalización $|w_1| + |w_2|$ es constante e igual a s, así que el minimizador no es único. Por eso pequeñas variaciones numéricas en los datos pueden desplazar la solución a lo largo de ese segmento, lo que produce una selección de variables inestable.

- **Selección de columnas:** Lasso textbfno elimina necesariamente una de las dos columnas en todas las soluciones. Aunque algoritmos numéricos como el descenso de coordenadas suelen converger hacia los vértices $(s, 0)$ o $(0, s)$ descartando una variable, cualquier punto interior del segmento (incluyendo la solución equitativa $w_1 = w_2 = s/2$) es matemáticamente un minimizador válido y óptimo que conserva ambas columnas en el modelo.

c) Cambio de escala, impacto en la regularización y estandarización

1. Coeficiente equivalente que conserva las predicciones: Sea la predicción original para una observación n:

$$\hat{y}_n = \sum_{k \neq j} w_k x_{nk} + w_j x_{nj} + b \tag{53}$$

Si se reemplaza únicamente la característica j por $x'_{nj} = a x_{nj}$ con $a > 0$, buscamos el nuevo coeficiente w'_j que mantenga inalterada la predicción $\hat{y}'_n = \hat{y}_n$:

$$\hat{y}'_n = \sum_{k \neq j} w_k x_{nk} + w'_j (a x_{nj}) + b = \hat{y}_n \implies w'_j (a x_{nj}) = w_j x_{nj} \implies w'_j = \frac{w_j}{a} \tag{54}$$

2. Cambio en las contribuciones a las penalizaciones L_1 y L_2: Evaluando el impacto de la reescalación $w_j \to w'_j = \frac{w_j}{a}$ en las normas de regularización:

- **Penalización L_1 (Lasso):**

$$\lambda_1 |w'_j| = \lambda_1 \left| \frac{w_j}{a} \right| = \frac{1}{a} \left(\lambda_1 |w_j| \right) \tag{55}$$

  La contribución a la penalización L_1 se reduce en un factor de $\frac{1}{a}$.

- **Penalización L_2 (Ridge):**

$$\frac{\lambda_2}{2} (w'_j)^2 = \frac{\lambda_2}{2} \left(\frac{w_j}{a} \right)^2 = \frac{1}{a^2} \left(\frac{\lambda_2}{2} w_j^2 \right) \tag{56}$$

  La contribución a la penalización L_2 se reduce en un factor cuadrático de $\frac{1}{a^2}$.

3. Justificación del impacto de las unidades en la regularización: Las normas de regularización $\|w\|_1$ y $\|w\|_2^2$ penalizan la magnitud de los coeficientes suponiendo implícitamente que todas las características están en escalas comparables. Si una característica x_j se mide en unidades muy pequeñas (por ejemplo, milímetros, resultando en $a \gg 1$), el modelo requiere un coeficiente w_j pequeño, lo que disminuye artificialmente su penalización y favorece la retención de esa variable. Por el contrario, si se mide en unidades grandes ($a \ll 1$), el coeficiente w_j debe crecer, sufriendo una penalización desproporcionada que puede eliminar injustificadamente la variable del modelo.

4. Estimación de estadísticas del escalador dentro de cada partición de entrenamiento: Las estadísticas de escalado (como la media μ_j y la desviación estándar σ_j) deben estimarse exclusivamente dentro de la partición de entrenamiento para prevenir la **fuga de información** (*data leakage*). Calcular estas métricas sobre el conjunto de datos completo contamina el entrenamiento con información no observada del conjunto de prueba/validación, produciendo estimaciones de rendimiento artificialmente optimistas e invalidando la auditoría metodológica del modelo.

5. Distinción frente a una conversión de unidades fija:

- **Conversión de unidades fija:** Es una transformación determinista definida *a priori* mediante un factor constante conocido a (por ejemplo, convertir metros a kilómetros dividiendo por 1000), el cual es independiente de la muestra y no consulta las observaciones de datos.
- **Estandarización basada en datos:** Es una transformación estocástica empírica donde los factores de centrado y escala dependientes de la muestra ($\hat{\mu}_j$ y $\hat{\sigma}_j$) son estimadores estadísticos calculados a partir de los datos de entrenamiento.

Problema 3. Probabilidades, ponderación y decisiones

a) Derivación de la pérdida logística, gradientes, Hessiano y estabilidad numérica

1. Derivación de la pérdida logística desde la verosimilitud Bernoulli: Modelando la variable de respuesta condicionada a las características mediante una distribución de Bernoulli:

$$Y_n \mid x_n \sim \text{Bernoulli}(p_n), \quad p_n = \sigma(z_n) = \frac{1}{1+e^{-z_n}}, \quad z_n = w^\top x_n + b \tag{57}$$

La función de masa de probabilidad para cada observación $y_n \in \{0,1\}$ es $P(Y_n = y_n \mid x_n) = p_n^{y_n}(1-p_n)^{1-y_n}$. Asumiendo independencia condicional entre observaciones, la función de verosimilitud $L(w,b)$ es:

$$L(w,b) = \prod_{n=1}^{N} p_n^{y_n}(1-p_n)^{1-y_n} \tag{58}$$

Aplicando logaritmo natural, obtenemos la función de log-verosimilitud $\ell(w,b)$:

$$\ell(w,b) = \sum_{n=1}^{N} [y_n \log p_n + (1-y_n)\log(1-p_n)] \tag{59}$$

Minimizar la log-verosimilitud negativa por muestra es equivalente a minimizar la función de pérdida por entropía cruzada binaria $J_{\log}(w,b)$:

$$J_{\log}(w,b) = -\frac{1}{N}\ell(w,b) = -\frac{1}{N}\sum_{n=1}^{N} [y_n \log p_n + (1-y_n)\log(1-p_n)] \tag{60}$$

2. Formulación equivalente mediante la función $\log(1+e^z)$: Sustituyendo $p_n = \frac{e^{z_n}}{1+e^{z_n}}$ y $1-p_n = \frac{1}{1+e^{z_n}}$:

$$\log p_n = z_n - \log(1+e^{z_n}) \quad \text{y} \quad \log(1-p_n) = -\log(1+e^{z_n}) \tag{61}$$

Sustituyendo estas expresiones en la suma:

$$y_n \log p_n + (1-y_n)\log(1-p_n) = y_n\left(z_n - \log(1+e^{z_n})\right) - (1-y_n)\log(1+e^{z_n}) = y_n z_n - \log(1+e^{z_n}) \tag{62}$$

Multiplicando por $-\frac{1}{N}$, obtenemos la formulación equivalente:

$$J_{\log}(w,b) = \frac{1}{N}\sum_{n=1}^{N}\left[\log(1+e^{z_n}) - y_n z_n\right] \tag{63}$$

3. Gradientes y Hessiano en la parametrización aumentada θ: Definiendo el vector de características aumentado $\tilde{x}_n = \begin{bmatrix} 1 \\ x_n \end{bmatrix} \in \mathbb{R}^{D+1}$, la matriz aumentada $\tilde{X} = [\mathbf{1}_N \quad X] \in \mathbb{R}^{N\times(D+1)}$ y el vector de parámetros $\theta = \begin{bmatrix} b \\ w \end{bmatrix} \in \mathbb{R}^{D+1}$, de modo que $z_n = \tilde{x}_n^\top \theta$:

- **Gradiente respecto a w, b y θ:** Dado que $\frac{\partial \log(1+e^{z_n})}{\partial z_n} = p_n$, la derivada parcial respecto a la puntuación es $\frac{\partial J_{\log}}{\partial z_n} = \frac{1}{N}(p_n - y_n)$. Por consiguiente:

$$\nabla_w J_{\log} = \frac{1}{N} X^\top (p-y), \quad \frac{\partial J_{\log}}{\partial b} = \frac{1}{N}\mathbf{1}_N^\top (p-y) \tag{64}$$

$$\nabla_\theta J_{\log}(\theta) = \frac{1}{N}\sum_{n=1}^{N}(p_n - y_n)\tilde{x}_n = \frac{1}{N}\tilde{X}^\top (p-y) \tag{65}$$

- **Hessiano respecto a θ:** Derivando el gradiente respecto a θ y notando que $\frac{\partial p_n}{\partial z_n} = p_n(1-p_n)$:

$$\nabla_\theta^2 J_{\log}(\theta) = \frac{1}{N}\sum_{n=1}^{N} p_n(1-p_n)\tilde{x}_n\tilde{x}_n^\top = \frac{1}{N}\tilde{X}^\top S\tilde{X} \tag{66}$$

  donde $S = \operatorname{diag}\left(p_1(1-p_1), \ldots, p_N(1-p_N)\right) \in \mathbb{R}^{N\times N}$.

4. Convexidad y condición para convexidad estricta:

- **Convexidad:** Para todo $\theta \in \mathbb{R}^{D+1}$ finito, $p_n \in (0,1)$, garantizando que S es una matriz diagonal estrictamente definida positiva ($S \succ 0$). Evaluando la forma cuadrática para $u \neq \mathbf{0}$:

$$u^\top \left(\nabla_\theta^2 J_{\log}\right) u = \frac{1}{N}(\tilde{X}u)^\top S(\tilde{X}u) \geq 0 \tag{67}$$

  Como $\nabla_\theta^2 J_{\log}(\theta) \succeq 0$, la función $J_{\log}(\theta)$ es **convexa**.

- **Convexidad estricta.** Por la expresión del Hessiano, $\nabla_\theta^2 J_{\log}(\theta) = \frac{1}{N}\tilde{X}^\top S(\theta)\tilde{X}$ con $S(\theta) \succ 0$ para todo $\theta \in \mathbb{R}^{D+1}$ finito, pues $p_n \in (0,1)$. Por tanto, para $u \neq 0$,

$$u^\top \nabla_\theta^2 J_{\log}(\theta)\, u = \frac{1}{N}(\tilde{X}u)^\top S(\theta)(\tilde{X}u) \geq 0, \tag{68}$$

  y $J_{\log}$ es convexa. Si $\operatorname{rango}(\tilde{X}) = D+1$, entonces $\tilde{X}u \neq 0$ para todo $u \neq 0$, y la igualdad anterior da $u^\top \nabla_\theta^2 J_{\log}(\theta)\, u > 0$ en todo θ. Esta condición es suficiente para la convexidad estricta.

Además, la condición de rango completo es también necesaria para la convexidad estricta de $J_{\log}$ sobre $\mathbb{R}^{D+1}$. Si existe $u \neq 0$ con $\tilde{X}u = 0$, entonces $\tilde{X}(\theta + tu) = \tilde{X}\theta$ para todo $t \in \mathbb{R}$, de modo que $J_{\log}$ es constante a lo largo de la recta $\theta + tu$ y no puede ser estrictamente convexa. Así, la propiedad se obtiene exactamente cuando $\text{rango}(\tilde{X}) = D + 1$.

5. Inexistencia de minimizador finito bajo separabilidad perfecta: Si las clases son perfectamente separables por un hiperplano, existe θ^* tal que $\text{sign}(\tilde{x}_n^\top \theta^*) = 2y_n - 1$. Si consideramos direcciones de búsqueda escaladas $k\theta^*$ con $k \to \infty$:

$$\lim_{k\to\infty} \left[\log(1 + e^{kz_n^*}) - y_n(kz_n^*)\right] = 0, \quad \forall n \in \{1, \ldots, N\} \tag{69}$$

Por ende, $\lim_{k\to\infty} J_{\log}(k\theta^*) = 0$. Dado que $J_{\log}(\theta) > 0$ para todo θ finito, el ínfimo se aproxima asintóticamente pero **no existe un minimizador finito** ($\|\theta\|_2 \to \infty$), provocando divergencia en algoritmos de optimización sin regularización.

6. Evaluación numéricamente estable de la pérdida: Para evitar el desbordamiento numérico (*overflow*) al calcular e^z con $z \gg 0$, empleamos la identidad Log-Sum-Exp:

$$\log(1 + e^z) = \text{máx}(0, z) + \log(1 + e^{-|z|}) \tag{70}$$

Reemplazando en la pérdida individual de la n-ésima observación:

$$\ell_n(z_n, y_n) = \text{máx}(0, z_n) - y_n z_n + \log(1 + e^{-|z_n|}) \tag{71}$$

Esta formulación es numéricamente estable en todo el dominio $\mathbb{R}$, al evaluar siempre el exponencial con un argumento no positivo ($-|z_n| \leq 0$), previniendo *overflows* e imprecisiones numéricas.

b) Regla de decisión óptima de Bayes, comparación de umbrales y capacidad

1. Derivación de la regla de decisión y umbral teórico óptimo: Sea $p = P(Y = 1 \mid x)$ la probabilidad verdadera de retraso observada para una instancia x. Definimos el espacio de acciones de decisión $\hat{y} \in \{0, 1\}$, donde $\hat{y} = 1$ representa emitir una alerta y $\hat{y} = 0$ no emitirla, con la siguiente matriz de costos:

- $C(\hat{y} = 1, Y = 0) = C_{FP} = 1$ (Costo de una alerta innecesaria / Falso Positivo)
- $C(\hat{y} = 0, Y = 1) = C_{FN} = 12$ (Costo de un retraso no alertado / Falso Negativo)
- $C(\hat{y} = 1, Y = 1) = C_{TP} = 0$ y $C(\hat{y} = 0, Y = 0) = C_{TN} = 0$ (Decisiones correctas)

El costo condicional esperado para cada acción posible dado x corresponde a:

$$\mathbb{E}[C \mid x, \hat{y} = 1] = C_{TP} \cdot p + C_{FP} \cdot (1 - p) = 1 - p \tag{72}$$

$$\mathbb{E}[C \mid x, \hat{y} = 0] = C_{FN} \cdot p + C_{TN} \cdot (1 - p) = 12p \tag{73}$$

La regla de decisión de Bayes minimiza el costo esperado eligiendo alertar ($\hat{y} = 1$) si y solo si $\mathbb{E}[C \mid x, \hat{y} = 1] \leq \mathbb{E}[C \mid x, \hat{y} = 0]$:

$$1 - p \leq 12p \iff 1 \leq 13p \iff p \geq \frac{1}{13} \tag{74}$$

Por consiguiente, la regla óptima de decisión adopta la forma de umbral $\hat{y} = \mathbb{I}(p \geq \tau^*)$, con un **umbral teórico óptimo**:

$$\tau^* = \frac{C_{FP}}{C_{FP} + C_{FN}} = \frac{1}{1 + 12} = \frac{1}{13} \approx 0{,}07692 \quad (7{,}69\,\%) \tag{75}$$

2. Evaluación para una probabilidad $p = 0{,}10$ y comparación con $\tau = 0{,}5$: Para una observación con probabilidad condicional de retraso $p = 0{,}10$:

- **Costos esperados condicionales por acción:**

$$\mathbb{E}[C \mid \hat{y} = 1] = 1 - 0{,}10 = \mathbf{0{,}90}, \quad \mathbb{E}[C \mid \hat{y} = 0] = 12 \times 0{,}10 = \mathbf{1{,}20} \tag{76}$$

- **Decisión con umbral óptimo $\tau^* = \frac{1}{13} \approx 0{,}0769$:** Como $p = 0{,}10 \geq \frac{1}{13}$, la regla selecciona $\hat{y} = 1$ (Emitir alerta), incurriendo en un costo esperado de **0.90**.
- **Decisión con umbral estándar $\tau = 0{,}5$:** Como $p = 0{,}10 < 0{,}5$, la regla selecciona $\hat{y} = 0$ (No emitir alerta), incurriendo en un costo esperado de **1.20**.

Comparación: El umbral simétrico $\tau = 0{,}5$ asume erróneamente que cometer un falso positivo es tan costoso como un falso negativo ($C_{FP} = C_{FN}$). En este escenario fuertemente asimétrico ($C_{FN} = 12C_{FP}$), adoptar $\tau = 0{,}5$ genera un sobrecosto del **33.3 %** (1,20 frente a 0,90) al no tomar una acción preventiva justificada.

3. Análisis sobre las restricciones operativas y la capacidad de alertas: El umbral teórico $\tau^* = \frac{1}{13}$ es un criterio de minimización puntual e individual que opera de forma local sobre la probabilidad $p(x)$.

El volumen global de alertas emitidas en el sistema depende directamente de la distribución marginal de las características $P(X)$ en la población, es decir, $P(\text{Alerta}) = P(p(X) \geq \tau^*)$. Si las condiciones operativas se deterioran y la mayoría de los vuelos presentan probabilidades $p(x) \geq 0{,}0769$, la regla óptima teórica ordenará alertar sobre todos ellos, pudiendo sobrepasar la capacidad logística disponible. Por ende, el umbral no impone una capacidad máxima por sí solo; para garantizar restricciones de capacidad globales (por ejemplo, no emitir alertas sobre más del 15 % de los vuelos) se requiere optimizar la política incorporando restricciones presupuestarias o de capacidad explícitas.

c) Pérdida logística ponderada, minimizador condicional y recalibración

1. Obtención del minimizador q^*: Dada la función de riesgo condicional para una observación con característica x:

$$\mathcal{R}(q) = -a_1 p \log q - a_0(1-p)\log(1-q), \quad a_0, a_1 > 0, \quad 0 < p, q < 1 \tag{77}$$

Para encontrar el minimizador q^*, derivamos $\mathcal{R}(q)$ respecto a q e igualamos a cero:

$$\frac{d\mathcal{R}(q)}{dq} = -\frac{a_1 p}{q} + \frac{a_0(1-p)}{1-q} = 0 \implies a_1 p(1-q) = a_0(1-p)q \tag{78}$$

$$a_1 p - a_1 pq = a_0(1-p)q \implies a_1 p = [a_1 p + a_0(1-p)]\, q \tag{79}$$

Despejando q^*:

$$q^* = \frac{a_1 p}{a_1 p + a_0(1-p)} \tag{80}$$

Verificando la condición de segundo orden para confirmar un mínimo estricto:

$$\frac{d^2\mathcal{R}(q)}{dq^2} = \frac{a_1 p}{q^2} + \frac{a_0(1-p)}{(1-q)^2} > 0, \quad \forall q \in (0,1) \tag{81}$$

2. Condición bajo la cual $q^* = p$: Igualando $q^* = p$:

$$q^* = p \iff \frac{a_1 p}{a_1 p + a_0(1-p)} = p \iff a_1 = a_1 p + a_0(1-p) \iff a_1(1-p) = a_0(1-p) \quad (82)$$

Dado que $p \in (0,1) \implies 1 - p \neq 0$, la igualdad se cumple si y solo si:

$$a_1 = a_0 \quad (83)$$

Por ende, $q^* = p$ únicamente cuando las clases no están ponderadas ($a_1 = a_0$). Si $a_1 \neq a_0$, q^* es una probabilidad distorsionada que no refleja la probabilidad posterior verdadera p.

3. Evaluación de la aplicación del umbral teórico $\tau^* = 1/13$ sobre q^*: No es correcto aplicar directamente el umbral no ponderado $\tau^* = \frac{1}{13}$ sobre la salida predictiva q^* si $a_1 \neq a_0$.

El umbral $\tau^* = \frac{1}{13}$ fue derivado asumiendo que el predictor estima la probabilidad condicional verdadera $p = P(Y = 1 \mid x)$. Si evaluamos la regla $\hat{y} = \mathbf{1}\left(q^* \geq \frac{1}{13}\right)$ en términos de p:

$$\frac{a_1 p}{a_1 p + a_0(1-p)} \geq \frac{1}{13} \iff 13 a_1 p \geq a_1 p + a_0(1-p) \iff p \geq \frac{a_0}{12 a_1 + a_0} \quad (84)$$

Si por ejemplo la pérdida se entrenó con ponderación $a_1/a_0 = 12$, la salida q^* ya incorpora internamente el costo asimétrico. Aplicar nuevamente el umbral $\tau^* = 1/13$ sobre q^* penalizaría dos veces la asimetría, distorsionando la regla de decisión óptima. Para operar con q^*, se debe recalibrar la predicción para recuperar p o ajustar adecuadamente el umbral sobre q^*.

Aspecto	**Poblacional Ideal ($N \to \infty$, capacidad infinita)**	**Muestra Finita, Modelo Restringido y Regularización**
Relación q^* vs. p	Relación analítica puntual directa: $q^*(x) = \frac{a_1 p(x)}{a_1 p(x) + a_0(1-p(x))}$.	La relación exacta se destruye. En modelos de capacidad limitada (p. ej., lineales), la frontera de decisión cambia.
Efecto de la ponderación	No altera el espacio de hipótesis; únicamente mapea la probabilidad monótonamente.	Prioriza el ajuste sobre la clase ponderada, reduciendo su error a costa de descalibrar las probabilidades globales.
Efecto de regularización	Inexistente.	Penalizaciones como L_2 contraen coeficientes, reduciendo la varianza de las puntuaciones y distorsionando la calibración.
Recuperación de p	Inversión analítica exacta: $p = \frac{a_0 q^*}{a_0 q^* + a_1(1-q^*)}$.	Requiere métodos de recalibración empírica (p. ej., *Platt Scaling* o *Isotonic Regression*) en conjunto de validación.